

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ
PRÓ-REITORIA DE PESQUISA, PÓS-GRADUAÇÃO E INOVAÇÃO
PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO CIENTÍFICA

PIBIC - 2020/2021

RELATÓRIO FINAL

AVALIAÇÃO DO DESEMPENHO DE TÉCNICAS DE
DEEP LEARNING PARA CLASSIFICAÇÃO DO
COMPORTAMENTO TEMPORAL DE AÇÕES

JÚLIO CESAR NIEVOLA

CURITIBA

2021

GABRIEL HENRIQUE PRZYTOCKI
JÚLIO CESAR NIEVOLA

CIÊNCIA DA COMPUTAÇÃO – ESCOLA POLITÉCNICA
BOLSA PIBIC – PUCPR

AVALIAÇÃO DO DESEMPENHO DE TÉCNICAS DE
DEEP LEARNING PARA CLASSIFICAÇÃO DO
COMPORTAMENTO TEMPORAL DE AÇÕES

Relatório Final apresentado ao Programa Institucional de Bolsas de Iniciação Científica, Pró-Reitoria de Pesquisa e Pós-Graduação da Pontifícia Universidade Católica do Paraná, e órgãos de fomento, sob orientação do **Prof. Dr. Júlio Cesar Nievola**.

Lista de Figuras

1	Representação de uma rede convolucional (CNN).	17
2	Representação de uma unidade LSTM, com componentes estruturais e operações matemáticas.	17
3	Dados históricos da ação PETR4.SA (Petrobrás), no ano de 2020. . . .	19
4	(a) Altas e baixas; (b) Aberturas e fechamentos; ações PETR4.SA, ano de 2020.	20
5	Dados históricos das cotações em formato de <i>candlestick</i> ; ações PETR4.SA, ano de 2020.	20
6	Retornos diários; ações PETR4.SA, 2020.	21
7	Parâmetros utilizados para o treino da rede CNN.	23
8	Parâmetros utilizados nos testes com a rede LSTM.	23
9	: Fluxograma do algoritmo “ <i>Classifications Trading</i> ”.	24
10	Fluxograma adaptado dos experimentos realizados, com diagrama incluindo treino e teste de diferentes modelos em diferentes períodos, bem como a operação de <i>trading</i> com diferentes algoritmos.	30
11	Previsões do CNN, seguido dos preços de fechamento reais e as operações de compra e venda, para 2020.	31
12	Previsões do LSTM, seguido dos preços de fechamento reais e as operações de compra e venda, para 2020.	32
13	Operações do algoritmo <i>Naive Trading</i> , sem modelo, para o ano de 2020.	32
14	Comparação das métricas categóricas entre o CNN e o modelo <i>Naive</i> , bem como a acurácia média das operações com lucro (última métrica).	34
15	Diferentes métricas, na média, para os modelos testados, bem como acurácia das operações com lucro (primeira métrica).	35
16	Distribuição das acurácias para os experimentos realizados com o CNN, em todos os períodos, bem como as distribuições para as operações que utilizaram as previsões do CNN, para todos os resultados em todos os períodos.	36

Lista de Tabelas

1	Bibliotecas utilizadas, suas respectivas versões e propósitos.	18
2	Características de hardware do ambiente de processamento utilizado. .	18
3	Estatísticas sobre os dados históricos da ação PETR4.SA, para o ano de 2020.	21
4	Períodos de treino e teste.	22
5	Períodos de simulação de operação (<i>trading</i>).	22
6	Divisão percentual, dos períodos de treino, teste e operação, em percentuais (os intervalos de teste e trading são os mesmos para cada período).	22
7	Algoritmo de <i>trading</i> escolhido para cada técnica utilizada para realizar previsões, com o respectivo número de ações negociadas em cada operação, e os períodos diferentes para teste e operação.	29
8	Médias dos resultados de todos os períodos dos testes feitos com cada técnica treinada, utilizando as saídas numéricas geradas pelo algoritmo e comparando os preços de fechamento com os preços reais observados.	33
9	Médias dos resultados de todos os períodos dos testes feitos com cada técnica, utilizando as classificações geradas pelo algoritmo e comparando os movimentos classificados como “alta” e “baixa” com os movimentos reais.	33
10	Médias dos resultados de todos os períodos dos testes feitos com cada técnica combinada a um algoritmo de <i>trading</i>	33
11	Médias dos resultados de todos os períodos dos testes feitos com cada técnica combinada a um algoritmo de <i>trading</i>	34
12	Critérios para avaliar os modelos segundo suas métricas.	37
13	Resultados categóricos de todos os experimentos para os testes com o CNN. Ações PETR4.SA.	41
15	Resultados categóricos de todos os experimentos para os testes com o LSTM. Ações PETR4.SA.	42
17	Resultados categóricos de todos os experimentos para os testes com os Modelos <i>Naive</i> e AR. Ações PETR4.SA.	42
19	Resultados numéricos de todos os experimentos para os testes com o CNN. Ações PETR4.SA.	43
21	Resultados numéricos de todos os experimentos para os testes com o LSTM. Ações PETR4.SA.	44
23	Resultados numéricos de todos os experimentos para os testes com os Modelos <i>Naive</i> e AR. Ações PETR4.SA.	44

Lista de Algoritmos

1	Pseudocódigo do algoritmo <i>classifications_trading</i> (c, \vec{p}_c, \vec{p}_p)	25
2	Pseudocódigo do algoritmo <i>naive_trading</i> (c, \vec{p}_c)	26

Lista de Símbolos

\vec{p}_c	<i>array com preços de fechamento de uma determinada ação</i>
\vec{p}_p	<i>array com preços previstos por algum modelo para os fechamentos de uma ação</i>
c	<i>carteira inicial para uma operação de trading</i>
k	<i>constante do modelo Autorregressivo</i>
ε	<i>ruído branco</i>
θ	<i>valor observado</i>
$\hat{\theta}$	<i>valor estimado</i>

Lista de Abreviações

AR	<i>Acurácia das Operações com Lucro</i>
AOL	<i>Convolutional Neural Network - Rede Neural Convolucional</i>
CI	<i>Carteira Inicial</i>
CF	<i>Carteira Final</i>
ET	<i>Estratégia de Trading</i>
FP	<i>False Positive - Falso Positivo</i>
FN	<i>False Negative - Falso Negativo</i>
LSTM	<i>Long Short-Term Memory</i>
MSE	<i>Mean Squared Error - Erro quadrático médio</i>
QAC	<i>Quantidade de Ações Compradas</i>
RC	<i>Razão entre as Carteiras</i>
RMT	<i>Real Movements Trading</i>
TP	<i>True Positive - Verdadeiro Positivo</i>
TN	<i>True Negative - Verdadeiro Negativo</i>

Sumário

LISTA DE FIGURAS		iii
LISTA DE TABELAS		iv
LISTA DE ALGORITMOS		v
LISTA DE SÍMBOLOS		vi
LISTA DE ABREVIACÕES		vii
SUMÁRIO		viii
RESUMO		x
1	INTRODUÇÃO	11
2	OBJETIVOS	12
2.0.1	Objetivos específicos	12
3	REVISÃO DE LITERATURA	13
3.0.1	Mercado de Ações	13
3.0.2	Métodos de Análise e Previsão de Ações	14
3.0.2.1	Análise Técnica	14
3.0.2.2	Análise Fundamentalista	14
3.0.2.3	Séries Temporais	14
3.0.3	Previsão em Séries Temporais	15
3.0.3.1	Modelo Autorregressivo (<i>Autoregressive Model</i> ou AR)	15
3.0.4	Previsão em Séries Temporais Financeiras	16
3.0.5	Aprendizagem de Máquina (<i>Machine Learning</i>)	16
3.0.5.1	Aprendizagem Profunda (<i>Deep Learning</i>)	16
3.0.5.1.1	Rede Neural Convolucional (<i>Convolutional Neural Network</i> ou CNN)	17
3.0.5.1.2	Memória de Longo e Curto Prazo (<i>Long Short-Term Memory</i> ou LSTM)	17
4	MATERIAIS E MÉTODO	18
4.0.1	Materiais	18
4.0.2	Método	19
4.0.2.1	Características dos Dados	19
4.0.2.2	Treino e teste do CNN e LSTM	21
4.0.2.3	Parâmetros dos modelos utilizados	22
4.0.3	Algoritmos de Trading	24
4.0.3.1	Algoritmo <i>Classifications Trading</i> (CT)	24
4.0.3.2	Algoritmo <i>Naive Trading</i> (NT)	25
4.0.3.3	Algoritmo <i>Real Movements Trading</i> (RMT)	26

4.0.4	Métricas de avaliação utilizadas	26
4.0.4.1	Métricas de Teste	27
4.0.4.1.1	<i>Métricas para as Saídas numéricas</i>	27
4.0.4.1.2	<i>Métricas para as saídas categóricas</i>	27
4.0.4.2	Métricas para o período de <i>trading</i>	28
4.0.5	Ordem dos experimentos realizados	29
5	RESULTADOS	31
5.0.1	Previsões com CNN e Operações com Classifications Trading	31
5.0.2	Previsões com LSTM e Operações com <i>Classifications Trading</i>	32
5.0.3	Operações com <i>Naive Trading</i>	32
5.0.4	Médias dos resultados dos testes com as saídas numéricas	33
5.0.5	Médias dos resultados dos testes com as saídas categóricas	33
5.0.6	Médias dos resultados das operações	33
6	DISCUSSÃO	35
7	CONSIDERAÇÕES FINAIS	39
	REFERÊNCIAS	40
	ANEXOS	41

Resumo

A previsão de movimentos no mercado de ações é uma tarefa complexa, apresentando inúmeras abordagens que objetivam uma maximização dos lucros em contrapartida de uma minimização das perdas e dos riscos por parte dos investidores. As técnicas mais recentes de redes neurais (CNN e LSTM), apesar de seu ótimo desempenho em inúmeras áreas, contrastam com a ausência de trabalhos voltados para sua utilização no mercado de ações. Este trabalho buscou comparar tais técnicas com o modelo Autorregressivo, clássico na previsão em séries temporais, bem como a modelos mais simples e “ingênuos” de previsão, de maneira a ter uma base maior de discussão. Os modelos foram testados com as ações PETR4.SA (Petrobrás) para os anos 2019 e 2020, oscilando em períodos diferentes de treino e teste, bem como repetindo os experimentos para uma maior assertividade dos resultados. As previsões geradas pelos modelos foram ainda submetidas à operações de *trading* nos períodos de teste, utilizando classificações de “alta” e “baixa” em relação ao preço de fechamento do dia seguinte na tomada de decisão. Os rótulos dos movimentos foram gerados através de um algoritmo específico que separava em uma das duas classes os preços numéricos obtidos pelos modelos. Os resultados apontaram que a técnica CNN apresentou um desempenho aproximado em relação ao modelo Autorregressivo em termos de acurácia de operações com lucro (60%), bem como +73% desta acurácia em relação ao *Naive Model* (Modelo Ingênuo) e +20% em relação ao algoritmo de investimento *Naive Trading* (Trading Ingênuo, utilizando apenas os preços dos dois dias anteriores para a tomada de decisão). Os experimentos realizados nas condições específicas deste trabalho, em termos dos parâmetros utilizados e o período da ação em questão, demonstraram que o LSTM teve um desempenho ineficaz no que diz respeito às classificações dos movimentos e operação de *trading*, bem como um desempenho comparável ao modelo autorregressivo em termos de previsões numéricas, considerando a proximidade como o valor real de fechamento. A técnica CNN foi especialmente eficiente para os propósitos deste trabalho, tal como é ressaltado na bibliografia consultada em relação ao seu uso para predição em séries temporais.

Palavras-chave: *Deep Learning*, CNN, LSTM, Mercado de Ações, Séries Temporais.

1 Introdução

A previsão de movimentos do mercado financeiro é objeto de estudo de inúmeras abordagens, historicamente se adaptando para elevar ao máximo a precisão de seus modelos preditivos e inevitavelmente culminando na instrumentalização da tecnologia para o processamento e implementação de técnicas cada vez mais completas e precisas, diante da volatilidade e o volume massivo de dados característicos deste mercado. (SEN; CHAUDHURI, 2016).

Consequentemente, é evidente o crescimento da abordagem baseada nas Técnicas de Aprendizagem de Máquina (“*Machine Learning*”) no que tange à análise de **Séries Temporais Financeiras**, especificamente mencionando as técnicas de *Deep Learning*, notoriamente expressivas nos últimos cinco anos¹. Tais abordagens relacionadas à Séries Temporais Financeiras partem da análise do histórico passado de uma ação, e ações similares, realizando assim aproximações acerca de seu comportamento futuro; os padrões extraídos usualmente são combinados a técnicas específicas de mineração de dados, tais como associação, agrupamento, classificação, sumarização e regressão (FU, 2011). As Séries Temporais Financeiras são um subcampo de estudo de uma área matemática e estatística denominada de Séries Temporais, como é o caso das Séries provenientes da bolsa de valores: essencialmente dinâmicas, não lineares, complexas, não paramétricas e caóticas (ABU-MOSTAFA; ATIYA, 1996).

Considerando a motivação dos investidores ao elaborar uma carteira, objetiva-se obter lucro máximo, em contrapartida de um risco mínimo; assim, torna-se evidente a problemática aqui destacada: diante da complexidade do problema, quais são as melhores formas de se utilizar as técnicas atuais de *Deep Learning* na **classificação** e predição dos movimentos futuros da Bolsa de Valores? Em decorrência dos fatores acima mencionados, a emergência da nova abordagem, especialmente no que se refere às técnicas de *Deep Learning*, considerando sua eficácia em inúmeros campos, contrastam com a ausência de trabalhos que busquem avaliar seu desempenho e identificar situações potenciais de uso, justificando assim a análise e avaliação a serem feitas nesse trabalho.

¹ Disponível em: [Google Acadêmico](#). Acesso em 30 jan. 2021.

2 Objetivos

Avaliar o desempenho de algoritmos de *Deep Learning* (CNN e LSTM), classificando o movimento de uma ação para o dia seguinte em “crescente” ou “decrecente”, simulando operações de compra e venda de ações a fim de avaliar seus desempenhos.

2.0.1 Objetivos específicos

- Determinar o conjunto de atributos a serem utilizados para previsão, tendo em vista o classificador a ser utilizado;
- Realizar a criação de uma base com os atributos adequados ao classificador;
- Selecionar atributos respectivos às duas bases - original e criada;
- Implementar os algoritmos de *Deep Learning* (CNN e LSTM);
- Executar algoritmos de regressão sobre as bases;
- Analisar os resultados, comparando as técnicas utilizadas nas bases e identificando assim situações potenciais para o uso desta abordagem.

3 Revisão de Literatura

As abordagens que buscam realizar previsões no mercado financeiro utilizam inúmeros conceitos na composição de seus modelos, e tangem inúmeras áreas do conhecimento, tais como: estatística, mercado financeiro, economia e computação. Historicamente, há também diferentes formas de análise no que diz respeito a tomada de decisão no mercado financeiro, que também serão apresentadas. Abaixo estão separados subtópicos referentes a conceitos importantes para a literatura de Séries Temporais Financeiras.

3.0.1 Mercado de Ações

O conceito de Ação representa uma fração do capital social de uma empresa quaisquer, ou seja, títulos que são vendidos em diferentes níveis de participação para compor uma sociedade investidora. O mercado de ações representa essa forma das empresas de obter capital que posteriormente é aplicado em recursos que possibilitará o crescimento desta, e conseqüentemente no lucro dos compradores através da distribuição de dividendos. Os investidores têm a expectativa de lucrar com empresas que geram lucro e se valorizam. O valor das ações é volátil, sofre influência de inúmeras direções, tais como as leis do mercado, a lei da oferta e procura, fatores macroeconômicos, notícias, taxas e juros bancários, decisões dos investidores ([CHEN; DA; ZHAO, 2013](#)). Seguem abaixo alguns atributos respectivos a ações, usualmente utilizados para exemplificá-las, também presentes em gráficos do mercado financeiro, conjuntos de dados e afins:

- *Open*: Preço de abertura; corresponde ao preço da primeira negociação do período.
- *High*: Preço máximo; corresponde ao maior valor alcançado no período.
- *Low*: Preço mínimo; corresponde ao valor mais baixo do período.
- *Close*: Preço de fechamento; corresponde ao valor da última negociação do período.
- *Volume*: Volume; é o total de ações negociadas durante o período.

Tais atributos apresentados estão presentes nos indicadores financeiros, utilizados vastamente pelos analistas a fim de procurar e entender padrões no mercado. ([ACHELIS, 2006](#)).

3.0.2 Métodos de Análise e Previsão de Ações

A previsão de ações ou movimentos na bolsa de valores ocorre quando as séries temporais extraídas não seguem *random walks* - movimentos aleatórios e imprevisíveis, portanto não passíveis de previsão (BROWNLEE, 2017) - (CASTELÃO, 2018)

3.0.2.1 Análise Técnica

Análise que se baseia nas forças que regem as decisões dos investidores, criando uma dinâmica com os valores passados, projetando-os para o futuro mediante análise de gráficos e da utilização de indicadores. Ignora fatores externos e foca nas mudanças das ações, na tentativa de prever anomalias e movimentos. Dentre os indicadores utilizados, podemos citar: indicadores de filtro, indicadores de volume, indicadores de momento, entre outros (CASTELÃO, 2018).

3.0.2.2 Análise Fundamentalista

A análise fundamentalista se baseia nos fatores micro e macroeconômicos de uma empresa para inferir a respeito da dinâmica do mercado de ações. Analisa os fatores humanos, os setores e a organização interna de uma empresa, seu estado atual, suas relações e os fatores externos. Possui a vantagem de poder realizar previsões antes mesmo destas aparecerem nos gráficos, bem como a desvantagem de automatizar devido a complexidade e subjetividade das análises (CASTELÃO, 2018).

3.0.2.3 Séries Temporais

Por fim, temos as séries temporais, de nosso interesse para esse relatório. Séries Temporais são séries em que as observações apresentam uma dependência sequencial, de forma que em um tempo t , as observações $t - 1$, $t - 2$ em diante apresentam influência nos valores futuros. Séries Temporais são conjuntos dessas observações com intervalos regulares de tempo (BROWNLEE, 2017).

Podemos também destacar os componentes característicos de uma séries temporal¹:

- *tendência*: indica seu comportamento “a longo prazo”, bem como sua velocidade de mudança.
- *ciclo*: oscilação de subida e descida na série, de forma repetitiva e característica.
- *sazonalidade*: oscilações de subida e descida características associadas a períodos específicos, como por exemplo períodos do ano.

¹ [Análise de Séries Temporais: PUC-Rio](#). Acesso em 14 mai. 2021.

3.0.3 Previsão em Séries Temporais

Tipicamente, um conjunto de dados da bolsa de valores apresenta a característica de ser separado por unidades de tempo, usualmente em dias, tal qual uma ação fecha o dia com um determinado preço que é denominado de “*close*”. No estudo de estatística e mineração de dados, uma série numérica com essa característica temporal, separada em períodos, é denominada de série temporal. Séries temporais podem ser obtidas de inúmeras aplicações científicas, em fenômenos da natureza e em aplicações financeiras. Dentre os exemplos de Séries temporais, pode-se destacar: eletrocardiogramas, temperaturas diárias, vendas semanais de produtos, bolsa de valores, entre outros. No tocante às características das Séries temporais, os dados podem estar distribuídos de forma sazonal ou aleatória. A Série pode ainda ser estacionária ou não estacionária. As abordagens da análise de Séries temporais buscam a extração de informações do passado para estudar comportamentos futuros através dos métodos de análise e da aplicação dos modelos de predição, identificando padrões diversos (FU, 2011). Seguem abaixo alguns modelos estatísticos de predição de dados utilizados em séries temporais:

- Modelo de Médias Móveis (*Moving Average* ou MA)
- Modelo Autorregressivo (*Autoregressive model* ou AR)
- Modelo Autorregressivo de Médias Móveis (*Autoregressive-moving-average* ou ARMA)
- Modelo Autorregressivo Integrado de Médias Móveis (*Autoregressive integrated moving average* ou ARIMA)

3.0.3.1 Modelo Autorregressivo (*Autoregressive Model* ou AR)

O modelo Autorregressivo é utilizado para realizar previsões em Séries Temporais, utilizando observações passadas em uma equação regressiva para prever os valores futuros. O modelo AR é uma combinação linear de valores, passados como *input*, que geram *outputs* tratados como previsões da série (BROWNLEE, 2017). Este modelo pertence à família de modelos estatísticos tradicionais para a previsão em séries temporais; por ser robusto, foi utilizado neste trabalho para trazer uma base comparativa. O modelo Autorregressivo de ordem p , $AR(p)$, se dá pela equação abaixo²:

$$X_t = k + \sum_{i=1}^p \varphi_i X_{t-i} + \varepsilon_t \quad (3.1)$$

Onde $\varphi_1, \dots, \varphi_n$ são os parâmetros do modelo, k é uma constante e ε_t é o ruído branco.

² Disponível em: [Portal Action: Modelos Autorregressivos](#). Acesso em 13 mai. 2021.

3.0.4 Previsão em Séries Temporais Financeiras

A partir das técnicas de análise de Séries Temporais Financeiras, podemos extrair padrões característicos, tais como sazonalidade, ciclos, tendência e caminhada aleatória. Os padrões extraídos usualmente são combinados a técnicas específicas de mineração de dados, tais como associação, agrupamento, classificação, sumarização e regressão (FU, 2011). Como mencionado, as Séries Temporais podem ainda ser estacionárias, ou então não estacionárias, como é o caso das séries provenientes da bolsa de valores. As estacionárias flutuam entorno de uma mesma média ao longo do tempo, em contrapartida das não estacionárias (FU, 2011). Na análise das características de uma série do mercado de ações, há períodos que podem conter tendências, ciclos e caminhadas aleatórias (random walks) ou então uma combinação um ou mais desses três elementos. A previsão em séries temporais do mercado de ações, portanto, é essencialmente dinâmica, não linear, complexa, não paramétrica e caótica (ABU-MOSTAFA; ATIYA, 1996).

3.0.5 Aprendizagem de Máquina (*Machine Learning*)

Como mencionado anteriormente, a abordagem de *Machine Learning* vem utilizando técnicas para realizar previsões em séries temporais. Em aprendizagem de máquina, podemos citar algumas formas distintas de aprendizado:

- Aprendizagem supervisionada
- Aprendizagem não supervisionada
- Aprendizagem semi-supervisionada
- Aprendizagem por reforço

Podemos citar, no que tange a aprendizagem supervisionada, as técnicas de aprendizagem profunda *Deep Learning*, dos quais utilizaremos as técnicas CNN e LSTM neste relatório.

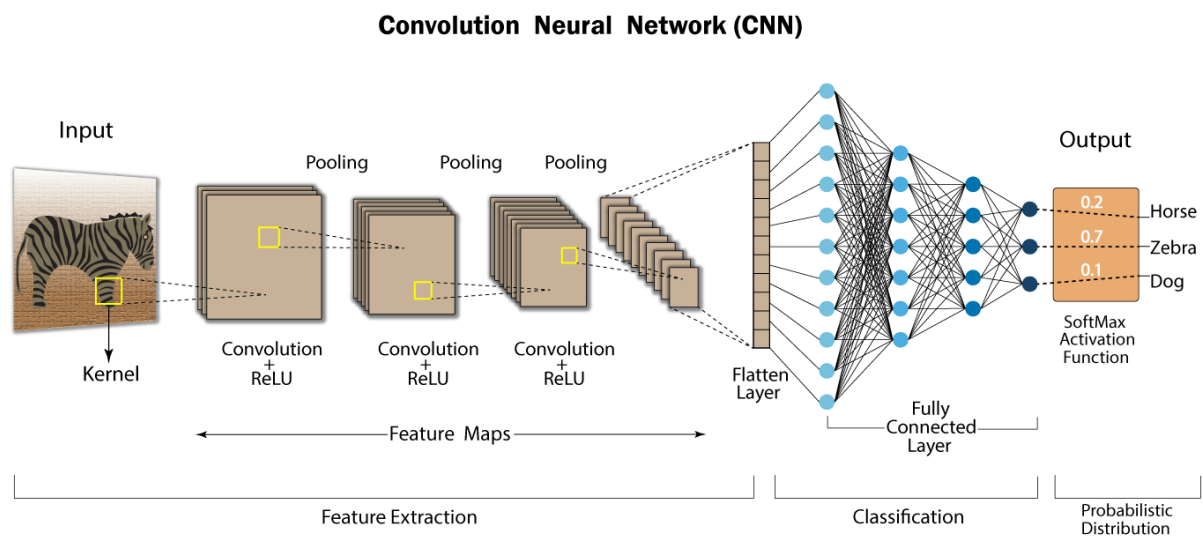
3.0.5.1 Aprendizagem Profunda (*Deep Learning*)

As técnicas de aprendizagem profunda são eficazes em realizar o aprendizado por meio de representações computacionais de elementos diversos, como imagens, músicas e afins. Essas representações simples geram processos de aprendizagem extremamente complexos (GOODFELLOW; BENGIO; COURVILLE, 2016). Os tópicos abaixo tratam de duas técnicas de *Deep Learning* que serão utilizadas neste relatório.

3.0.5.1.1 Rede Neural Convolucional (Convolutional Neural Network ou CNN)

A técnica CNN é especializada em processamento de dados em topologia de grade, como pode ser o caso das Séries Temporais (de nosso interesse), através dos dados passados como uma grade de uma dimensão, em intervalos regulares (GOODFELLOW; BENGIO; COURVILLE, 2016).

Figura 1 – Representação de uma rede convolucional (CNN).




Fonte: [Developers Breach](#). Acesso 13 de mai. 2021.

3.0.5.1.2 Memória de Longo e Curto Prazo (Long Short-Term Memory ou LSTM)

As LSTMs são redes neurais recorrentes, e foram introduzidas por Hochreiter & Schmidhuber (1997). Possuem uma vasta aplicação em inúmeras áreas e são extensamente utilizadas no mercado financeiro (CASTELÃO, 2018). A técnica LSTM também apresenta resultados eficientes nas áreas de reconhecimento de voz, reconhecimento de dígitos escritos à mão, entre outros (GOODFELLOW; BENGIO; COURVILLE, 2016).

Figura 2 – Representação de uma unidade LSTM, com componentes estruturais e operações matemáticas.



Fonte: [Colah's Blog](#). Acesso 13 de mai. 2021.

4 Materiais e Método

4.0.1 Materiais

Em relação ao ambiente de execução, foram utilizados dois ambientes: o primeiro foi o Google Colab para a análise dos resultados e exploração dos dados históricos das ações, utilizando Python em sua versão 3.7.10 (x64); o segundo foi o PyCharm utilizando Python 3.7.0 (x64), destinado para o processamento dos modelos e geração dos resultados. Para possibilitar a implementação das técnicas de Deep Learning (CNN e LSTM) e do modelo Autorregressivo utilizados, bem como a aplicação dos algoritmos e transformações dos dados, algumas bibliotecas da linguagem Python compuseram uma referência base para sua concretização, e estão contidas na tabela abaixo:

Tabela 1 – Bibliotecas utilizadas, suas respectivas versões e propósitos.

Bibliotecas	Versão	Descrição
numpy	1.19.5	funções matemáticas e transformações de matrizes
matplotlib	3.2.2	plotagem de gráficos
pandas_datareader	0.9.0	carregamento dos dados históricos, API do yahoo
pandas	1.1.5	carregamento e transformações de dados
sklearn	0.22.2.post1	métricas para avaliação e pré-processamento dos dados
datetime	default	transformações de datas
statsmodels	0.10.2	modelo Autorregressivo
keras	2.4.3	modelos CNN e LSTM

Fonte: Autor do relatório.

Com relação ao hardware referente ao processamento e execução dos algoritmos, o ambiente utilizado foi:

Tabela 2 – Características de hardware do ambiente de processamento utilizado.

CPU	Intel(R) Core(TM) i7-7700HQ CPU @ 2.80GHz
Memória RAM	16GB
GPU	NVIDIA GeForce GTX 1050 Ti
Sistema Operacional (SO)	Microsoft Windows 10 Pro (x64)
Versão do SO	10.0.19042 N/A compilação 19042
Modelo do sistema	Nitro AN515-51
Tipo de sistema	x64-based PC

Fonte: Autor do relatório.

4.0.2 Método


O método empregado visa a mensuração e a comparação entre modelos relacionadas à Séries Temporais Financeiras, tratando-se de um método quantitativo, considerando que utiliza de uma abordagem estatística no que tange à comparação das técnicas existentes, a fim de estabelecer hipóteses de situações potenciais de uso destas, bem como identificá-las mediante análise (WAINER, 2007).

As redes neurais testadas (CNN e LSTM) foram treinadas com os preços de fechamento de cada dia dos períodos escolhidos, e então foi testada para um ano posterior ao ano final de treino. As saídas foram numéricas, e então comparadas com os fechamentos reais do ano em questão que foi realizado o teste. Para as saídas geradas, também, foi submetido um algoritmo que compara o preço atual previsto com o preço previsto do dia seguinte, e então classifica-o em “subida” ou “descida”; tais classificações foram comparadas aos movimentos reais obtidos nos fechamentos reais de cada dia, no caso se o preço do dia seguinte foi maior que o atual (subida), ou então foi menor que o atual (descida).

As técnicas de redes neurais CNN e LSTM foram testadas em diferentes períodos, e o experimento foi repetido 10 vezes para cada período devido aos processos estocásticos que ocorrem internamente no funcionamento das redes neurais. Os resultados obtidos foram comparados entre as técnicas, bem como os resultados dos processos de simulação de operação na bolsa de valores.


4.0.2.1 Características dos Dados

Figura 3 – Dados históricos da ação PETR4.SA (Petrobrás), no ano de 2020.



Fonte: Yahoo Finance. Acesso em 14 mai. 2021.

Figura 4 – (a) Altas e baixas; (b) Aberturas e fechamentos; ações PETR4.SA, ano de 2020.




Fonte: [Yahoo Finance](#). Acesso em 14 mai. 2021.

Figura 5 – Dados históricos das cotações em formato de *candlestick*; ações PETR4.SA, ano de 2020.



Fonte: [Yahoo Finance](#). Acesso em 14 mai. 2021.

Figura 6 – Retornos diários; ações PETR4.SA, 2020.



Fonte: O autor do relatório.

Tabela 3 – Estatísticas sobre os dados históricos da ação PETR4.SA, para o ano de 2020.

Métricas	2019	2020
<i>Contagem</i>	247	247
<i>Média</i>	27.248988	22.287895
<i>Std</i>	1.655566	4.605092
<i>Min</i>	23.910000	11.290000
<i>25%</i>	26.065000	19.639999
<i>50%</i>	27.129999	22.120001
<i>75%</i>	28.220000	25.710000
<i>Max</i>	30.969999	30.809999

Fonte: Autor do relatório.

4.0.2.2 Treino e teste do CNN e LSTM

O treino dos modelos, individualmente, foi dividido em diferentes períodos para uma maior variabilidade nos resultados, objetivando submeter o modelo a diferentes situações e registrar seu desempenho. Cada período corresponde a um experimento realizado, seguido da operação simulada na bolsa e a coleta das métricas. Os períodos considerados para treino, teste e simulação de operação de trading, para o CNN e o LSTM foram:

Tabela 4 – Períodos de treino e teste.

Período	Treino	Teste	Resumo
Período 1	01/01/2010 à 31/12/2018	01/01/2019 à 31/12/2019	2010-2018: <i>Treino</i> ; 2019: <i>Teste</i>
Período 2	01/01/2010 à 31/12/2019	01/01/2020 à 31/12/2020	2010-2019: <i>Treino</i> ; 2020: <i>Teste</i>
Período 3	01/01/2010 à 31/12/2018	01/01/2020 à 31/12/2020	2010-2018: <i>Treino</i> ; 2020: <i>Teste</i>

Fonte: Autor do relatório.

Tabela 5 – Períodos de simulação de operação (*trading*).

Período	Início trading	Fim trading
Período 1	01/01/2019	31/12/2019
Período 2	01/01/2020	31/12/2020
Período 3	01/01/2020	31/12/2020

Fonte: Autor do relatório.

Tabela 6 – Divisão percentual, dos períodos de treino, teste e operação, em percentuais (os intervalos de teste e trading são os mesmos para cada período).

Período	Treino	Teste	Trading
Período 1	89%	11%	11%
Período 2	90%	10%	10%
Período 3	89%	11%	11%

Fonte: Autor do relatório.

4.0.2.3 Parâmetros dos modelos utilizados

- CNN

A rede foi treinada com o atributo “*close*” de cada dia durante o período de treino, que corresponde ao preço de fechamento da ação naquele dia. As saídas geradas foram números que buscaram prever a ação do dia seguinte. Um algoritmo recebeu tais valores numéricos previstos e retornou as classificações de “alta” ou “baixa” para o dia de hoje, comparando com o preço de amanhã. Abaixo, segue o trecho do código com os parâmetros utilizados nos testes com o CNN:

- LSTM

De maneira semelhante à rede CNN, a rede LSTM foi utilizada para o treino com os preços de fechamentos das ações. A figura abaixo é um trecho de código com a declaração do modelo e os parâmetros utilizados nos testes:

Figura 7 – Parâmetros utilizados para o treino da rede CNN.

```

1 model = Sequential()
2
3 model.add(Conv1D(filters=128, kernel_size=2, activation='relu'))
4 model.add(Conv1D(filters=128, kernel_size=2, activation='relu'))
5 model.add(Conv1D(filters=128, kernel_size=2, activation='relu'))
6 model.add(MaxPooling1D(pool_size=2))
7 model.add(Flatten())
8 model.add(Dense(100, activation='sigmoid'))
9 model.add(Dense(1))
10
11 model.compile(optimizer='adam', loss='mean_squared_error')
12 model.fit(x_train, y_train, epochs=80, batch_size=60)

```

Fonte: Autor do relatório.

Figura 8 – Parâmetros utilizados nos testes com a rede LSTM.

```

1 model = Sequential()
2
3 model.add(LSTM(units=60, return_sequences=True, input_shape=(x_train.shape[1],
4     1)))
5 model.add(Dropout(0.1))
6 model.add(LSTM(units=60, return_sequences=True))
7 model.add(Dropout(0.1))
8 model.add(LSTM(units=60))
9 model.add(Dropout(0.1))
10 model.add(Dense(units=1))
11
12 model.compile(optimizer='adam', loss='mean_squared_error')
13 model.fit(x_train, y_train, epochs=60, batch_size=30)

```

Fonte: Autor do relatório.

- Modelo *Naive*

O Modelo *Naive* (Modelo “Ingênuo”, do inglês “*naive*”) se refere a um modelo utilizado como base de comparação para as redes neurais. A palavra “ingênuo” se refere à simplicidade do modelo: todas as “previsões” de um período p são obtidas por meio do valor do período $p - 1$. Dessa forma, todas as previsões são “projeções” dos dados para o futuro; em linhas gerais, representa a confiança de que os dados obtidos no passado se repetirão no presente (daí o termo “ingênuo”).

- Modelo Autorregressivo (AR)

Outro modelo utilizado para comparar com os resultados obtidos pelas redes neurais é o modelo Autorregressivo. Este modelo pertence à família de modelos estatísticos tradicionais para a previsão em séries temporais; por ser robusto, foi utilizado neste trabalho para trazer uma base comparativa.

Para o modelo Autorregressivo, foram utilizados 60 dias anteriores ao período de teste e operação para o treino. Por exemplo, para o teste e treino no ano de 2019, o

modelo utilizou 60 dias do final de 2018 para treiná-lo. O parâmetro *endog* do modelo foi o conjunto de preços de fechamento, e o *maxlag* foi 60.

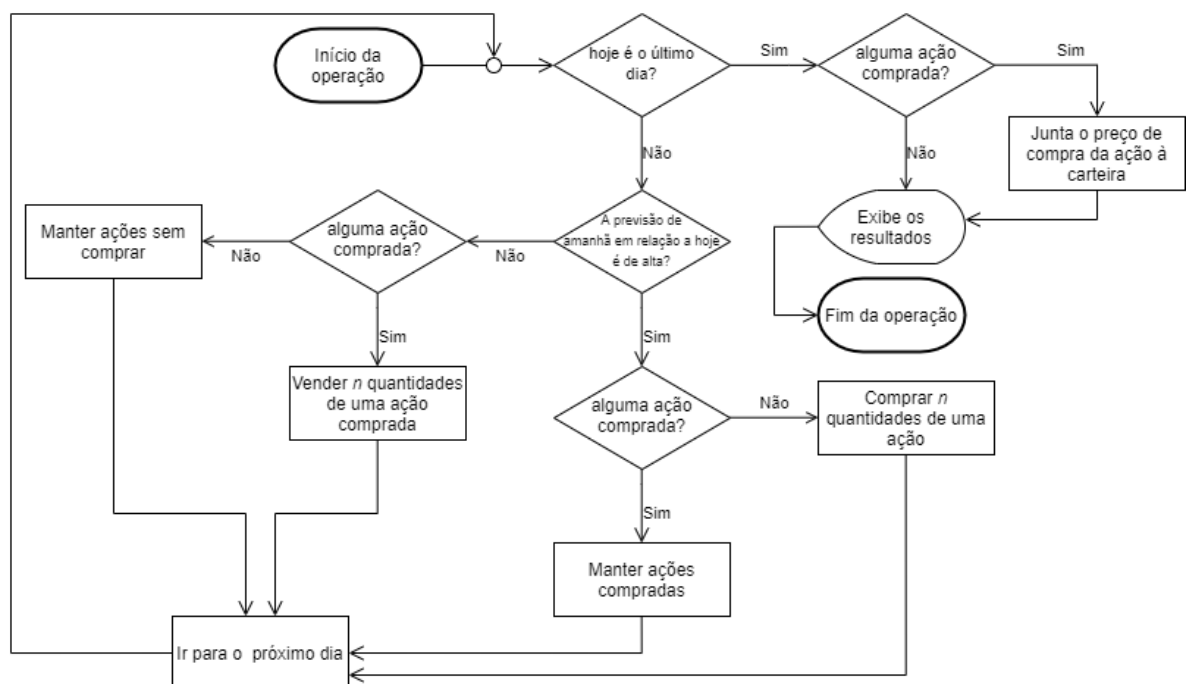
4.0.3 Algoritmos de Trading

São os algoritmos que realizam a simulação da operação de trading na bolsa de valores, cada um com uma regra específica associada à tomada de decisão.

4.0.3.1 Algoritmo *Classifications Trading* (CT)

Algoritmo de Trading que utiliza as classificações de “alta” ou “baixa” para o dia seguinte (em relação ao preço de fechamento) para tomar decisões a respeito da compra ou venda de ações (RITZMANN, 2016). Resumidamente, o algoritmo irá se basear na previsão do dia de hoje, comparando se o movimento previsto de hoje em relação a amanhã será de baixa ou alta. Por exemplo, o modelo CNN previu o valor R\$ 26,88 para o fechamento de amanhã, e o fechamento de hoje é de R\$ 24,90, logo será classificado como “alta” para hoje, pois amanhã o preço de fechamento subirá, logo o algoritmo fará uma compra.

Figura 9 – : Fluxograma do algoritmo “*Classifications Trading*”.



Fonte: O autor do relatório.

Algorithm 1 Pseudocódigo do algoritmo *classifications_trading*(c, \vec{p}_c, \vec{p}_p)**Entrada:** Carteira inicial c ; preços reais de fechamento \vec{p}_c ; preços previstos de fechamento \vec{p}_p

```

1: função CLASSIFICATIONSTRADING( $c, \vec{p}_c, \vec{p}_p$ )
2:    $\text{ultima\_compra} \leftarrow 0$ 
3:    $\text{acao\_comprada} \leftarrow \text{falso}$ 
4:   para  $\text{dia} \leftarrow \text{hoje}$  até  $\text{ultimo\_dia}$  faça
5:     se  $\text{hoje} == \text{ultimo\_dia}$  então
6:        $c \leftarrow c + \text{ultima\_compra}$ 
7:     senão
8:       se  $\vec{p}_p[\text{dia}] == \text{subida}$  então
9:         se  $\text{acao\_comprada} == \text{verdadeiro}$  então
10:           continuar
11:         senão
12:            $\text{comprar\_acao}(n\_acoes)$ 
13:            $\text{acao\_comprada} = \text{verdadeiro}$ 
14:         fim se
15:       senão
16:         se  $\text{acao\_comprada} == \text{verdadeiro}$  então
17:            $\text{vender\_acao}(n\_acoes)$ 
18:            $\text{acao\_comprada} = \text{falso}$ 
19:         senão
20:           continuar
21:         fim se
22:       fim se
23:     fim se
24:   fim para
25: fim função

```

4.0.3.2 Algoritmo *Naive Trading* (NT)

Algoritmo de Trading que utiliza uma técnica ingênua para tomada de decisão. Se o preço de fechamento de ontem for menor que o preço de fechamento de antes de ontem, infere-se que o mercado está em queda, portanto as ações serão vendidas. Caso contrário, ou seja, o preço de ontem é maior que o de antes de ontem, então compramos ações. A ideia desse algoritmo é ter uma base de comparação próxima do real, para os casos de compra e venda sem técnicas sofisticadas e afins, de maneira a averiguar o desempenho de tal técnica em relação às previsões provenientes das redes neurais.

Algorithm 2 Pseudocódigo do algoritmo *naive_trading*(c, \vec{p}_c)**Entrada:** Carteira inicial c ; preços reais de fechamento \vec{p}_c ;

```

1: função NAIVETRADING( $c, \vec{p}_c$ )
2:    $\text{ultima\_compra} \leftarrow 0$ 
3:    $\text{acao\_comprada} \leftarrow \text{falso}$ 
4:   para  $\text{dia} \leftarrow \text{hoje}$  até  $\text{ultimo\_dia}$  faça
5:     se  $\text{hoje} == \text{ultimo\_dia}$  então
6:        $c \leftarrow c + \text{ultima\_compra}$ 
7:     senão
8:       se  $\vec{p}_c[\text{dia} - 1] > \vec{p}_c[\text{dia} - 2]$  então
9:         se  $\text{acao\_comprada} == \text{verdadeiro}$  então
10:           continuar
11:         senão
12:            $\text{comprar\_acao}(n\_acoes)$ 
13:            $\text{acao\_comprada} = \text{verdadeiro}$ 
14:         fim se
15:       senão
16:         se  $\text{acao\_comprada} == \text{verdadeiro}$  então
17:            $\text{vender\_acao}(n\_acoes)$ 
18:            $\text{acao\_comprada} = \text{falso}$ 
19:         senão
20:           continuar
21:       fim se
22:     fim se
23:   fim se
24: fim para
25: fim função

```

4.0.3.3 Algoritmo *Real Movements Trading* (RMT)

O algoritmo “*Real Movements Trading*” é, na realidade, o mesmo algoritmo de “*Classifications Trading*”, com a única diferença que este utiliza os movimentos reais do período de operação, portanto é um algoritmo com 100% de precisão em relação às operações com lucro. A ideia desse algoritmo é ter uma base de comparação utópica, para um caso perfeito onde saberíamos todos os movimentos reais da bolsa de valores antes mesmo de acontecerem. Por exemplo, o preço de fechamento de amanhã será maior que o de hoje, então o movimento é classificado como “alta”, então o algoritmo efetua a compra de ações para aproveitar o aumento de preço em detrimento de uma compra com valor inferior ao de amanhã; o algoritmo só fará a venda das ações quando o movimento for de “descida”, então venderá todas as ações antes de obter prejuízo.

4.0.4 Métricas de avaliação utilizadas

Os testes com os modelos e as operações foram submetidos à métricas específicas para cada caso. Ao final, foram extraídas as médias e desvio-padrões dos resultados de cada métrica.

4.0.4.1 Métricas de Teste

As métricas utilizadas para avaliar o desempenho dos modelos em teste, logo após serem treinados e testados durante um ano. As saídas numéricas se referem ao preço de fechamento “previsto” pelo modelo. As saídas categóricas se referem as classificações geradas ao compararem os preços “previstos” para rotulá-las em “alta” ou “baixa”.

4.0.4.1.1 Métricas para as Saídas numéricas

- Coeficiente de determinação (*R squared* ou R2)

É uma medida de ajuste de um modelo linear generalizado, cuja equação é:

$$SQ_{\text{tot}} = \sum_{i=1}^n (y_i - \bar{y})^2 \quad (4.1)$$

Onde n é o número de observações, y_i é o valor observado e y é a média das observações.

- Erro Quadrático Médio (*Mean Squared Error* ou MSE)

É a média da diferença entre o valor real e previsto, cujo método é:

$$EQM(\hat{\theta}) = \frac{1}{N} \sum_{i=1}^N (\hat{\theta}_i - \theta_i)^2 \quad (4.2)$$

Onde θ é o valor estimado, θ_i o valor previsto e N o número de observações.

4.0.4.1.2 Métricas para as saídas categóricas

- Medida F (*F1-Score*)

Medida que utiliza *accuracy*, *precision* e *recall* para gerar um score, cujo método é:

$$F1 = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}} \quad (4.3)$$

- Acurácia (*Accuracy*)

Porcentagem de previsões corretas em relação ao total de previsões, cujo método é:

$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (4.4)$$

- Precisão (*Precision*)

Porcentagem de dados positivos entre todos os classificados como positivos, cujo método é:

$$precision = \frac{TP}{TP + FP} \quad (4.5)$$

- Revocação (*Recall*)

Indica o quão bem o modelo prevê positivos em relação ao total de positivos, cujo método é:

$$recall = \frac{TP}{TP + FN} \quad (4.6)$$

4.0.4.2 Métricas para o período de *trading*

- *Carteira final* (CF)

Valor da carteira, em R\$, no período final após completar a operação de trading.

- *Diferença das carteiras* (DC)

Diferença, em R\$, entre a carteira inicial (R\$ 100.000,00) e a carteira final da operação.

- *Razão entre as carteiras* (RC)

Razão entre a carteira final e a carteira inicial.

- *Qtd. De Operações com lucro* (QOL)

Dentre as operações realizadas (1 operação é o ato de compra e venda), é o número das que tiveram lucro.

- *Qtd. De Operações com perda* (QOP)

Dentre as operações realizadas, é o número das que tiveram prejuízo.

- *Acurácia de operações com lucro* (AOL)

Razão entre as operações com lucro e o total de operações realizadas.

- *Ganho médio por operações com lucro, em R\$* (GMO)

Dentre as operações com lucro, é a média entre o valor lucrado por operação.

4.0.5 Ordem dos experimentos realizados

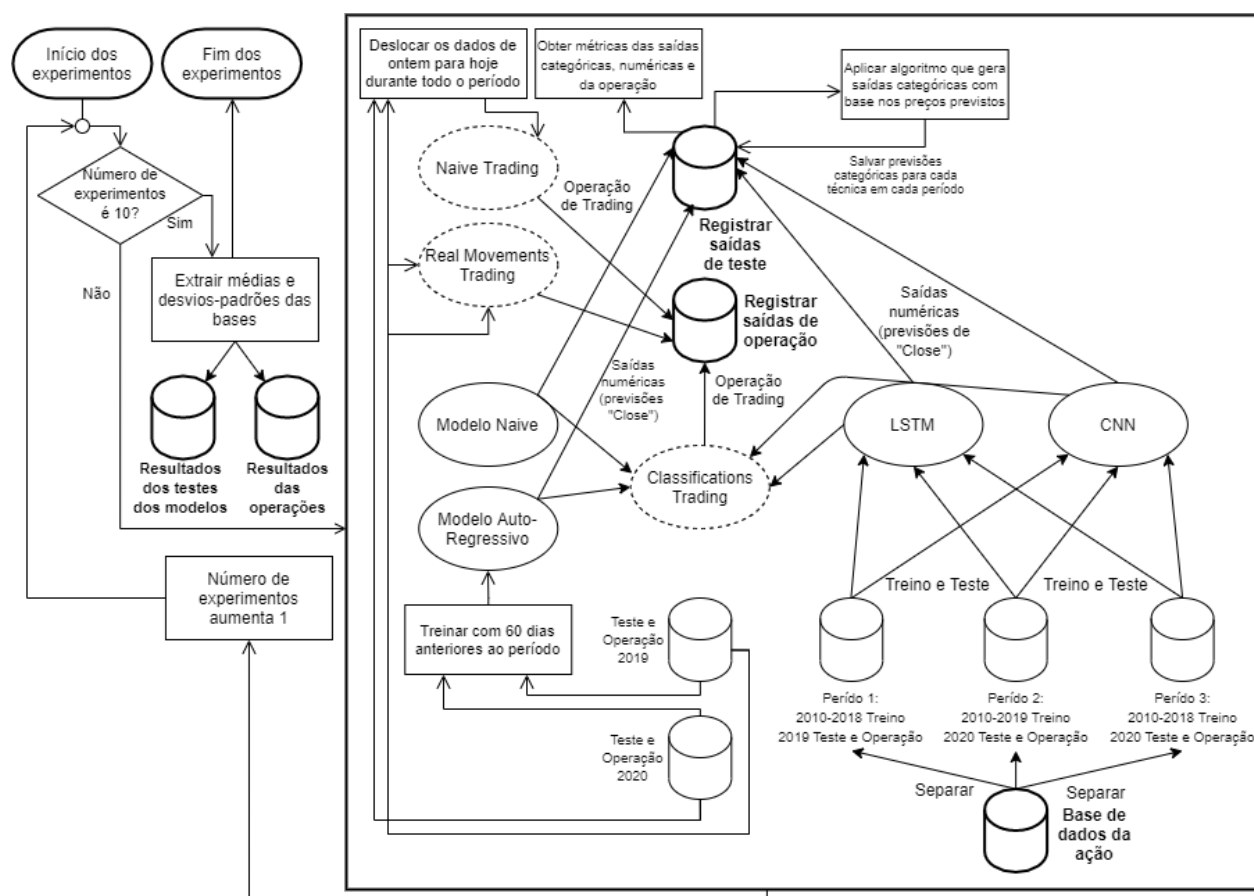
Os modelos utilizados, juntamente com os algoritmos de trading e os períodos de treino e operação, seguiram a tabela abaixo, que descreve os experimentos realizados:

Tabela 7 – Algoritmo de *trading* escolhido para cada técnica utilizada para realizar previsões, com o respectivo número de ações negociadas em cada operação, e os períodos diferentes para teste e operação.

Técnica	Algoritmo Trading	QAC	Período Trading	Repetições
CNN	Classificações	1500	Período 1, 2 e 3	10 vezes p/ cada período
LSTM	Classificações	1500	Período 1, 2 e 3	10 vezes p/ cada período
Modelo Naive	Classificações	1500	2019 e 2020	1 vez p/ cada período
Autorregressivo	Classificações	1500	2019 e 2020	1 vez p/ cada período
Modelo Naive	Classificações	1500	2019 e 2020	1 vez p/ cada período
Sem modelo	Naive Trading	1500	2019 e 2020	1 vez p/ cada período
Sem modelo	Movimentos Reais	1500	2019 e 2020	1 vez p/ cada período

Fonte: Autor do relatório.

Figura 10 – Fluxograma adaptado dos experimentos realizados, com diagrama incluindo treino e teste de diferentes modelos em diferentes períodos, bem como a operação de *trading* com diferentes algoritmos.




Fonte: O autor do relatório.

5 Resultados

Após realizar os experimentos para as ações PETR4.SA (Petrobrás), os modelos foram treinados, testados e avaliados em diferentes períodos, bem como suas previsões utilizadas em simulações de operações de trading. Os resultados dos 10 experimentos de cada período do CNN e LSTM foram submetidos à média e ao desvio padrão, e os demais testados para o ano de 2019 e 2020, posteriormente submetidos à média e desvio padrão também. Os gráficos de operações de trading abaixo são experimentos retirados dos testes feitos.

5.0.1 Previsões com CNN e Operações com Classifications Trading


Figura 11 – Previsões do CNN, seguido dos preços de fechamento reais e as operações de compra e venda, para 2020.



Fonte: O autor do relatório.

5.0.2 Previsões com LSTM e Operações com *Classifications Trading*


Figura 12 – Previsões do LSTM, seguido dos preços de fechamento reais e as operações de compra e venda, para 2020.



Fonte: O autor do relatório.

5.0.3 Operações com *Naive Trading*

Figura 13 – Operações do algoritmo *Naive Trading*, sem modelo, para o ano de 2020.



Fonte: O autor do relatório.

5.0.4 Médias dos resultados dos testes com as saídas numéricas

Tabela 8 – Médias dos resultados de todos os períodos dos testes feitos com cada técnica treinada, utilizando as saídas numéricas geradas pelo algoritmo e comparando os preços de fechamento com os preços reais observados.

Técnica	Ação	Período	R2	MSE (R\$) ²
CNN	PETR4.SA	Todos	0.825285	1.736832
LSTM	PETR4.SA	Todos	0.923408	0.769675
Modelo Naive	PETR4.SA	Todos	0.938442	0.475895
AR	PETR4.SA	Todos	0.955583	0.323019

Fonte: Autor do relatório.

5.0.5 Médias dos resultados dos testes com as saídas categóricas

Tabela 9 – Médias dos resultados de todos os períodos dos testes feitos com cada técnica, utilizando as classificações geradas pelo algoritmo e comparando os movimentos classificados como “alta” e “baixa” com os movimentos reais.

Técnica	Ação	Período	F1-Score	Acurácia	Precisão	Revocação
CNN	PETR4.SA	Todos	0.548317	0.527642	0.530769	0.567882
LSTM	PETR4.SA	Todos	0.480198	0.469783	0.47492	0.485627
Modelo Naive	PETR4.SA	Todos	0.488195	0.477642	0.487201	0.489198
AR	PETR4.SA	Todos	0.595666	0.583006	0.588752	0.60276

Fonte: Autor do relatório.

5.0.6 Médias dos resultados das operações

Tabela 10 – Médias dos resultados de todos os períodos dos testes feitos com cada técnica combinada a um algoritmo de *trading*.

Técnica	Ação	Período	ET	CI (R\$)	CF (R\$)	DC (R\$)	RC
CNN	PETR4.SA	Todos	Class. T.	100000.0	111,145.493793	11,145.493793	1.1114
LSTM	PETR4.SA	Todos	Class. T.	100000.0	96,990.799319	-3,009.200681	0.96990
Modelo Naive	PETR4.SA	Todos	Class. T.	100000.0	80,634.992361	-19,365.007639	0.80635
AR	PETR4.SA	Todos	Class. T.	100000.0	127,029.992104	27,029.992104	1.2703
Não possui	PETR4.SA	Todos	<i>Naive Trading</i>	100000.0	100,104.996681	104.996681	1.0010
Não possui	PETR4.SA	Todos	RMT	100000.0	184,105.011702	84,105.011702	1.8410

Fonte: Autor do relatório.


A figura abaixo compara algumas métricas utilizadas em teste, para os modelos CNN e *Naive*; a última métrica representa a acurácia das operações com lucro (AOP), sendo

Tabela 11 – Médias dos resultados de todos os períodos dos testes feitos com cada técnica combinada a um algoritmo de *trading*.

Técnica	Ação	Período	ET	QOL	QOP	AOL	GMO (R\$)
CNN	PETR4.SA	Todos	Class. T.	33.5	22.7	0.595812	196.77536
LSTM	PETR4.SA	Todos	Class. T.	19.5	33.0	0.372729	-56.297246
Modelo <i>Naive</i>	PETR4.SA	Todos	Class. T.	22.0	42.5	0.340909	18.793181
AR	PETR4.SA	Todos	Class. T.	40.5	25.5	0.615278	408.08322
Não possui	PETR4.SA	Todos	<i>Naive Trading</i>	31.5	32.0	0.496898	4.217068
Não possui	PETR4.SA	Todos	RMT	64.0	0.0	1.0	1,311.769415

Fonte: Autor do relatório.

uma métrica utilizada nas operações de trading de ambos os modelos. Essa comparação evidencia o desempenho da rede CNN diante de uma técnica simples de previsão em séries temporais.

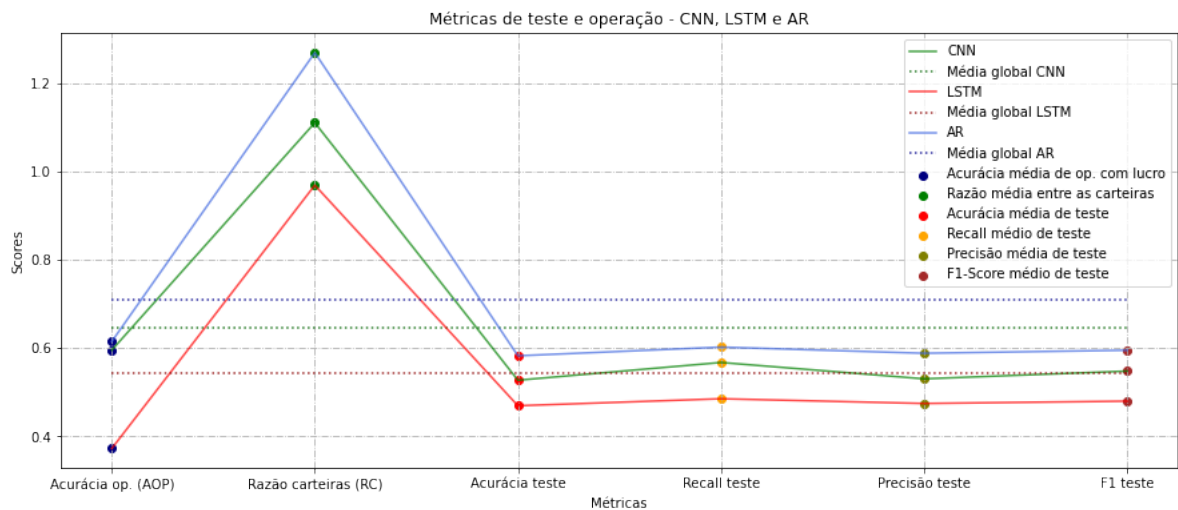
Figura 14 – Comparação das métricas categóricas entre o CNN e o modelo *Naive*, bem como a acurácia média das operações com lucro (última métrica).

Fonte: O autor do relatório.

6 Discussão

Analisando os resultados das tabelas, podemos observar que os melhores desempenhos foram do modelo Autorregressivo (AR) e a rede neural CNN. Os maiores lucros observados foram de ambos os modelos, com AR fechando uma carteira com +27% de lucro, e o CNN com a carteira com +11% de lucro, ambos com o investimento inicial de R\$ 100.000,00.

Figura 15 – Diferentes métricas, na média, para os modelos testados, bem como acurácia das operações com lucro (primeira métrica).




Fonte: O autor do relatório.

O AR é um modelo robusto utilizado em previsões em séries temporais, então seu ótimo desempenho foi esperado. Já o modelo LSTM, para os parâmetros aqui testados, não apresentou bons resultados, principalmente se comparado ao CNN. É notável que o LSTM teve as métricas numéricas muito mais precisas que ambos AR e CNN; isso significa que o modelo teve boa capacidade de aproximar o valor previsto do fechamento para o valor real de fechamento, que se ilustra no gráfico de operação do LSTM pela proximidade entre o real e o previsto. Apesar dos valores aproximados, entretanto, as medidas das saídas categóricas ficaram inferiores, tanto no F1-Score quanto na acurácia geral, exemplificando um lucro baixo (ou prejuízo), visto que o lucro é diretamente proporcional aos movimentos classificados corretamente o maior número de vezes possível.

O modelo AR apresentou média global maior que o CNN, mas suas acurácias médias de operações com lucro foram próximas, respectivamente 61% e 59%. Apesar das diferenças entre as acurácias no teste dos modelos (AR com 58% e CNN com 52%), o lucro final está diretamente relacionado com a porcentagem de operações com lucro, que em ambos os casos estão próximas de 60%.

A figura abaixo compara as funções densidade de probabilidade entre os valores obtidos nos experimentos de teste e *trading* para o modelo CNN, respectivamente utilizando as métricas de acurácia da previsão dos movimentos e a acurácia de lucro nas operações realizadas.

Figura 16 – Distribuição das acurácias para os experimentos realizados com o CNN, em todos os períodos, bem como as distribuições para as operações que utilizaram as previsões do CNN, para todos os resultados em todos os períodos.



Fonte: O autor do relatório.

Podemos notar que, para valores de acurácia em teste que tendem a 0.6, a acurácia de operações com lucro atinge, nessa posição, seu ponto médio. É possível traçar um paralelo entre a acurácia de teste e a acurácia de operação, levantando a hipótese de que existe uma relação diretamente proporcional entre as duas variáveis; esta hipótese também explicaria o porquê do modelo LSTM ter um desempenho ineficiente em operação, contrastando com sua precisão em termos numéricos (R^2 e MSE), visto que a proximidade do valor previsto com o real não implica em acertar o movimento das ações; podemos, por exemplo, prever um valor abaixo – ainda que próximo – de uma ação, e equivocadamente classificá-la em “baixa”.

Comparando as métricas de teste e acurácia de acerto em operação do CNN com o Modelo *Naive* (Figura 4.6.1), observamos a maior diferença na acurácia das operações com lucro, que salta de 34% para 59% (+73% de acurácia de acerto). É interessante notar que esse aumento possibilitou uma carteira final aproximadamente +38% acima do Modelo *Naive*, que na realidade finalizou com uma carteira em 80% do valor inicial (apresentou prejuízo). Também fica evidente a diferença quando comparamos o ganho médio (em R\$), para as operações com lucro, no qual o CNN apresenta aproximadamente +988% de lucro.

Comparando o desempenho em operação do CNN com o *Naive Trading*, a acurácia média de operações com lucro foi de +20% para o CNN, com lucro médio das operações

com lucro saltando de R\$ 4,21 para R\$ 192,77. O lucro final das carteiras aqui salta de R\$ 104,99 para R\$ 11.145,49 com o CNN.

O desempenho do CNN frente às técnicas ingênuas, tanto para o modelo *Naive* utilizando Classifications Trading quanto para o *Naive Trading* (operando sem modelo), se demonstrou mais eficiente e lucrativo. Entretanto, comparativamente ao modelo AR, seu desempenho em todos os casos foi inferior. Comparativamente, a média das diferenças entre as carteiras finais foi de R\$ 11.145,49 para o CNN, bem como R\$ 27.029,99 para o AR. É interessante notar que as acurácias de lucro por operações são semelhantes (aproximadamente 60%); para as acurácias máximas observadas durante os experimentos, o CNN teve a AOL atingindo 65% de operações com lucro, em contrapartida de 63% para o modelo AR.

Se compararmos o desempenho dos modelos com o algoritmo *Real Movements Trading*, podemos estabelecer um parâmetro de desempenho ótimo, do qual acerta todas as operações, e então avaliar cada técnica individualmente. O RMT fez 64 operações, das quais acertou todas, na média entre os anos 2019 e 2020. Para o CNN, temos 52% de acerto das operações considerando um desempenho perfeito; no caso do AR temos 63%; LSTM com 30%; Modelo *Naive* com 34%. É notável que o CNN e o AR tiveram desempenhos muito superiores às demais técnicas, e para as métricas, de forma geral, um desempenho próximo de 60% implica também em 60% de aproveitamento em relação ao desempenho perfeito.

Considerando como ideal o algoritmo RMT, bem como as métricas do modelo AR todas ótimas, os modelos foram avaliados segundo os critérios abaixo:

Tabela 12 – Critérios para avaliar os modelos segundo suas métricas.

0.65	\geq	<i>accuracy</i>	\geq	0.60	<i>ótimo</i>
0.60	$>$	<i>accuracy</i>	\geq	0.55	<i>bom</i>
0.55	$>$	<i>accuracy</i>	\geq	0.50	<i>razoável</i>
0.50	$>$	<i>accuracy</i>	\geq	0.00	<i>ruim</i>
1.00	\geq	R2	\geq	0.90	<i>ótimo</i>
0.90	$>$	R2	\geq	0.70	<i>bom</i>
0.70	$>$	R2	\geq	0.00	<i>ruim</i>
1.00	\geq	AOL	\geq	0.55	<i>ótimo</i>
0.55	$>$	AOL	\geq	0.50	<i>bom</i>
0.50	$>$	AOL	\geq	0.00	<i>ruim</i>

Fonte: Autor do relatório. Dados das tabelas 8, 9 e 11.

Para os experimentos realizados neste trabalho, observamos que:

- A *rede CNN* apresentou um desempenho **bom** na classificação dos movimentos
- A *rede CNN* apresentou um desempenho **razoável** nas previsões numéricas
- A *rede CNN* apresentou um desempenho **ótimo** para AOL em *trading*
- A *rede LSTM* apresentou um desempenho **ruim** nas classificações dos movimentos
- A *rede LSTM* apresentou um desempenho **ruim** para AOL em *trading*
- A *rede LSTM* apresentou um desempenho **bom** nas previsões numéricas
- O *modelo AR* apresentou um desempenho **ótimo** na classificação dos movimentos
- O *modelo AR* apresentou um desempenho **ótimo** nas previsões numéricas
- O *modelo AR* apresentou um desempenho **ótimo** para AOL em *trading*
- O *modelo Naive* apresentou um desempenho **ruim** na classificação dos movimentos
- O *modelo Naive* apresentou um desempenho **bom** nas previsões numéricas
- O *modelo Naive* apresentou um desempenho **ruim** para AOL em *trading*

7 Considerações Finais

O presente trabalho avaliou o desempenho das redes neurais CNN e LSTM para as ações PETR4.SA (Petrobrás), para os anos de 2019 e 2020, comparando com o modelo Autorregressivo – clássico na previsão em séries temporais – bem como comparando a um modelo simples (Modelo *Naive*) de previsão e uma técnica simples de operação na bolsa de valores (*Naive Trading*). A rede LSTM apresentou um desempenho muito semelhante aos modelos ingênuos, com prejuízo em relação ao valor investido inicialmente. Em contrapartida, a rede CNN teve um desempenho de +73% de acerto de operações com lucro em relação ao Modelo *Naive*, bem como +20% de lucro frente ao algoritmo Naive Trading. Ambas as redes (CNN e LSTM) tiveram desempenho geral inferior ao modelo AR. Entretanto, é notável que a acurácia média de operações com lucro do CNN foi de 59%, valor muito próximo ao do modelo AR, de 60%, levantando o questionamento a respeito da rede em diferentes ações para estabelecer uma base comparativa mais ampla em relação ao modelo AR.

Acerca das características específicas de cada rede, bem como potenciais situações de uso de cada uma frente a determinados problemas específicos, a CNN tem uma adaptação boa para a previsão que visa classificar valor em séries temporais (por exemplo em “alta” ou “baixa” para o movimento da bolsa de valores), visto que teve uma acurácia de operação muito próxima do modelo AR, que é robusto para problemas desta natureza. Já a rede LSTM, apesar de não ter apresentado grandes lucros para esse algoritmo em específico, treinada sob estas condições para a ação PETR4.SA, apresentou uma aproximação maior que o CNN para os valores numéricos em si; as previsões, ainda que classificadas incorretamente na maior parte dos casos, tiveram uma proximidade numérica maior com os valores reais de fechamento.

Por fim, a rede CNN apresentou um desempenho majoritariamente bom para a classificação dos movimentos previsão numérica e operação de trading; o modelo AR um desempenho ótimo; a rede LSTM um desempenho ruim (para os experimentos deste relatório); e o modelo *Naive*, um desempenho ruim também.

Referências

ABU-MOSTAFA, Y. S.; ATIYA, A. F. Introduction to financial forecasting. *Appl. Intell.*, v. 6, n. 3, p. 205–213, 1996. Disponível em: <<https://doi.org/10.1007/BF00126626>>. Citado 2 vezes nas páginas 11 e 16.

ACHELIS. *Technical Analysis From A To Z*. McGraw-Hill Education (India) Pvt Limited, 2006. ISBN 9780070636576. Disponível em: <<https://books.google.com.br/books?id=XJD8IbVj85oC>>. Citado na página 13.

BROWNLEE, J. *Introduction to Time Series Forecasting With Python: How to Prepare Data and Develop Models to Predict the Future*. Machine Learning Mastery, 2017. Disponível em: <<https://books.google.com.br/books?id=-AiqDwAAQBAJ>>. Citado 2 vezes nas páginas 14 e 15.

CASTELÃO. *Utilização de Redes Neurais para Previsões no Mercado de Ações*. [S.l.], 2018. Disponível em: <<https://www.ic.unicamp.br/~reltech/PFG/2018/PFG-18-01.pdf>>. Citado 2 vezes nas páginas 14 e 17.

CHEN, L.; DA, Z.; ZHAO, X. What Drives Stock Price Movements? *The Review of Financial Studies*, v. 26, n. 4, p. 841–876, 02 2013. ISSN 0893-9454. Disponível em: <<https://doi.org/10.1093/rfs/hht005>>. Citado na página 13.

FU, T. A review on time series data mining. *Eng. Appl. Artif. Intell.*, v. 24, n. 1, p. 164–181, 2011. Disponível em: <<https://doi.org/10.1016/j.engappai.2010.09.007>>. Citado 3 vezes nas páginas 11, 15 e 16.

GOODFELLOW, I. J.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016. <<http://www.deeplearningbook.org>>. Citado 2 vezes nas páginas 16 e 17.

RITZMANN, N. *Método para Otimização de Janelas de Tempo e Discretização para Classificação de Movimentos Futuros de Ações da Bolsa de Valores*. Dissertação (Mestrado), 2016. Disponível em: <<https://archivum.grupomarista.org.br/pergamumweb/vinculos/00005c/00005c6b.pdf>>. Citado na página 24.

SEN, J.; CHAUDHURI, T. D. A framework for predictive analysis of stock market indices : A study of the indian auto sector. *CoRR*, abs/1604.04044, 2016. Disponível em: <<http://arxiv.org/abs/1604.04044>>. Citado na página 11.

WAINER, J. *Métodos de pesquisa quantitativa e qualitativa para a Ciência da Computação*. Instituto de Computação – UNICAMP: Sociedade Brasileira de Computação e Editora PUC-Rio, 2007. <https://www.ic.unicamp.br/~wainer/cursos/1s2018/metodologia/Metodos_de_pesquisa_quantitativa_e_qualitativa_par.pdf>. Citado na página 19.

ANEXOS

Tabela 13 – Resultados categóricos de todos os experimentos para os testes com o CNN.
Ações PETR4.SA.

Tech.	Period	F1-Score	Accuracy	Precision	Recall
CNN	Ex1	0.529182879377432	0.508130081300813	0.53125	0.5271317829457365
CNN	Ex1	0.5140562248995985	0.508130081300813	0.5333333333333333	0.49612403100775193
CNN	Ex1	0.5440613026819924	0.516260162601626	0.5378787878787878	0.5503875968992248
CNN	Ex1	0.5176470588235295	0.5	0.5238095238095238	0.5116279069767442
CNN	Ex1	0.5606060606060607	0.5284552845528455	0.5481481481481482	0.5736434108527132
CNN	Ex1	0.5433962264150943	0.508130081300813	0.5294117647058824	0.5581395348837209
CNN	Ex1	0.5399239543726235	0.508130081300813	0.5298507462686567	0.5503875968992248
CNN	Ex1	0.5057471264367817	0.47560975609756095	0.5	0.5116279069767442
CNN	Ex1	0.5217391304347826	0.508130081300813	0.532258064516129	0.5116279069767442
CNN	Ex1	0.5627376425855514	0.532520325203252	0.5522388059701493	0.5736434108527132
CNN	Ex2	0.5612648221343873	0.5487804878048781	0.5419847328244275	0.5819672131147541
CNN	Ex2	0.5551330798479087	0.524390243902439	0.5177304964539007	0.5983606557377049
CNN	Ex2	0.5703125	0.5528455284552846	0.5447761194029851	0.5983606557377049
CNN	Ex2	0.5873015873015873	0.5772357723577236	0.5692307692307692	0.6065573770491803
CNN	Ex2	0.5612648221343873	0.5487804878048781	0.5419847328244275	0.5819672131147541
CNN	Ex2	0.5533596837944663	0.540650406504065	0.5343511450381679	0.5737704918032787
CNN	Ex2	0.5461538461538461	0.5203252032520326	0.5144927536231884	0.5819672131147541
CNN	Ex2	0.5511811023622047	0.5365853658536586	0.5303030303030303	0.5737704918032787
CNN	Ex2	0.5418326693227091	0.532520325203252	0.5271317829457365	0.5573770491803278
CNN	Ex2	0.5849802371541502	0.573170731707317	0.5648854961832062	0.6065573770491803
CNN	Ex3	0.5517241379310345	0.524390243902439	0.5179856115107914	0.5901639344262295
CNN	Ex3	0.5482625482625483	0.524390243902439	0.5182481751824818	0.5819672131147541
CNN	Ex3	0.5525291828793774	0.532520325203252	0.5259259259259259	0.5819672131147541
CNN	Ex3	0.5637065637065637	0.540650406504065	0.5328467153284672	0.5983606557377049
CNN	Ex3	0.5670498084291188	0.540650406504065	0.5323741007194245	0.6065573770491803
CNN	Ex3	0.5714285714285714	0.5487804878048781	0.5401459854014599	0.6065573770491803
CNN	Ex3	0.5354330708661418	0.5203252032520326	0.5151515151515151	0.5573770491803278
CNN	Ex3	0.5403225806451613	0.5365853658536586	0.5317460317460317	0.5491803278688525
CNN	Ex3	0.5307692307692307	0.5040650406504065	0.5	0.5655737704918032
CNN	Ex3	0.5363984674329502	0.508130081300813	0.5035971223021583	0.5737704918032787

Fonte: Autor do relatório.

Tabela 15 – Resultados categóricos de todos os experimentos para os testes com o LSTM.
Ações PETR4.SA.

Tech.	Period	F1-Score	Accuracy	Precision	Recall
LSTM	Ex1	0.53639846743295	0.508130081300813	0.5303030303030303	0.5426356589147286
LSTM	Ex1	0.5230769230769231	0.4959349593495935	0.5190839694656488	0.5271317829457365
LSTM	Ex1	0.5454545454545454	0.5121951219512195	0.5333333333333333	0.5581395348837209
LSTM	Ex1	0.5343511450381678	0.5040650406504065	0.5263157894736842	0.5426356589147286
LSTM	Ex1	0.5134099616858238	0.483739837398374	0.5075757575757576	0.5193798449612403
LSTM	Ex1	0.5267175572519084	0.4959349593495935	0.518796992481203	0.5348837209302325
LSTM	Ex1	0.5267175572519084	0.4959349593495935	0.518796992481203	0.5348837209302325
LSTM	Ex1	0.5267175572519084	0.4959349593495935	0.518796992481203	0.5348837209302325
LSTM	Ex1	0.5267175572519084	0.4959349593495935	0.518796992481203	0.5348837209302325
LSTM	Ex1	0.53639846743295	0.508130081300813	0.5303030303030303	0.5426356589147286
LSTM	Ex2	0.44715447154471544	0.44715447154471544	0.4435483870967742	0.45081967213114754
LSTM	Ex2	0.4426229508196721	0.44715447154471544	0.4426229508196721	0.4426229508196721
LSTM	Ex2	0.44897959183673464	0.45121951219512196	0.44715447154471544	0.45081967213114754
LSTM	Ex2	0.45528455284552843	0.45528455284552843	0.45161290322580644	0.45901639344262296
LSTM	Ex2	0.45528455284552843	0.45528455284552843	0.45161290322580644	0.45901639344262296
LSTM	Ex2	0.45967741935483875	0.45528455284552843	0.4523809523809524	0.4672131147540984
LSTM	Ex2	0.44715447154471544	0.44715447154471544	0.4435483870967742	0.45081967213114754
LSTM	Ex2	0.44897959183673464	0.45121951219512196	0.44715447154471544	0.45081967213114754
LSTM	Ex2	0.44897959183673464	0.45121951219512196	0.44715447154471544	0.45081967213114754
LSTM	Ex2	0.46586345381526106	0.45934959349593496	0.4566929133858268	0.47540983606557374
LSTM	Ex3	0.44897959183673464	0.45121951219512196	0.44715447154471544	0.45081967213114754
LSTM	Ex3	0.45528455284552843	0.45528455284552843	0.45161290322580644	0.45901639344262296
LSTM	Ex3	0.44897959183673464	0.45121951219512196	0.44715447154471544	0.45081967213114754
LSTM	Ex3	0.44715447154471544	0.44715447154471544	0.4435483870967742	0.45081967213114754
LSTM	Ex3	0.4738955823293172	0.46747967479674796	0.4645669291338583	0.48360655737704916
LSTM	Ex3	0.4677419354838709	0.4634146341463415	0.4603174603174603	0.47540983606557374
LSTM	Ex3	0.45967741935483875	0.45528455284552843	0.4523809523809524	0.4672131147540984
LSTM	Ex3	0.45714285714285713	0.45934959349593496	0.45528455284552843	0.45901639344262296
LSTM	Ex3	0.46341463414634143	0.4634146341463415	0.4596774193548387	0.4672131147540984
LSTM	Ex3	0.4677419354838709	0.4634146341463415	0.4603174603174603	0.47540983606557374

Fonte: Autor do relatório.

Tabela 17 – Resultados categóricos de todos os experimentos para os testes com os Modelos *Naive* e AR. Ações PETR4.SA.

Tech.	Period	F1-Score	Accuracy	Precision	Recall
NaiveModel	2019	0.5173745173745173	0.491869918699187	0.5153846153846153	0.5193798449612403
NaiveModel	2020	0.45901639344262296	0.4634146341463415	0.45901639344262296	0.45901639344262296
AR	2019	0.6106870229007634	0.5853658536585366	0.6015037593984962	0.6201550387596899
AR	2020	0.5806451612903225	0.5806451612903226	0.576	0.5853658536585366

Fonte: Autor do relatório.

Tabela 19 – Resultados numéricos de todos os experimentos para os testes com o CNN.
Ações PETR4.SA.

Technique	Period	R2	MSE
CNN	Ex1	0.7409600698366627	0.7071280989877579
CNN	Ex1	0.7744072259203597	0.6158239364090463
CNN	Ex1	0.7236396078445226	0.7544095561529484
CNN	Ex1	0.6664315079400696	0.9105764255102317
CNN	Ex1	0.7293308136789511	0.7388736827448995
CNN	Ex1	0.8111188781874434	0.5156083408367592
CNN	Ex1	0.8086823141243957	0.5222596818592742
CNN	Ex1	0.7694312933834196	0.6294072542910387
CNN	Ex1	0.003418895865899274	2.720470551428551
CNN	Ex1	0.7862764324809105	0.5834233352107557
CNN	Ex2	0.9250771658653769	1.5824464406425935
CNN	Ex2	0.9066214417411109	1.9722501004647754
CNN	Ex2	0.9237674521319672	1.6101089264472688
CNN	Ex2	0.9134325635623104	1.8283922818540497
CNN	Ex2	0.8947168147584748	2.223687927309407
CNN	Ex2	0.9171876681447931	1.749080654772332
CNN	Ex2	0.9180176940021546	1.7315496646703985
CNN	Ex2	0.9193704507460738	1.7029780667163776
CNN	Ex2	0.9321053127232057	1.4340048325808783
CNN	Ex2	0.9328207899246346	1.418893226568651
CNN	Ex3	0.869597661898784	2.754229977592125
CNN	Ex3	0.8741389566730846	2.6583132142381376
CNN	Ex3	0.8949573273441773	2.2186080569391686
CNN	Ex3	0.8257447259070094	3.680448576680632
CNN	Ex3	0.8828565131017034	2.4741895582004916
CNN	Ex3	0.8871628845974796	2.383234613365769
CNN	Ex3	0.8751848789621279	2.6362222719693014
CNN	Ex3	0.8957664753563332	2.201518028157177
CNN	Ex3	0.8733456923251288	2.6750677638812506
CNN	Ex3	0.8829722772323817	2.4717445020482276

Fonte: Autor do relatório.

Tabela 21 – Resultados numéricos de todos os experimentos para os testes com o LSTM. Ações PETR4.SA.

Technique	Period	R2	MSE
LSTM	Ex1	0.8213656989177447	0.4876365340997921
LSTM	Ex1	0.9109662993250351	0.24304450462303154
LSTM	Ex1	0.8373155619569385	0.4440965427057684
LSTM	Ex1	0.8660970981962868	0.3655286053455144
LSTM	Ex1	0.8983449342702255	0.2774983506853371
LSTM	Ex1	0.8998865263241204	0.27329010735467396
LSTM	Ex1	0.907004365714876	0.2538598047209779
LSTM	Ex1	0.9066769386926534	0.2547536161408444
LSTM	Ex1	0.764787144244965	0.6420848687021465
LSTM	Ex1	0.8042446187834573	0.534373717978516
LSTM	Ex2	0.9651290494597162	0.7365099332086771
LSTM	Ex2	0.9615129159486208	0.8128863499528622
LSTM	Ex2	0.9630346350371938	0.7807460954739213
LSTM	Ex2	0.9630283131827208	0.7808796194686373
LSTM	Ex2	0.9616574063651643	0.8098345654334002
LSTM	Ex2	0.9638026743089009	0.7645243250907723
LSTM	Ex2	0.9522486097928561	1.0085579161788687
LSTM	Ex2	0.963435088474156	0.7722881116925616
LSTM	Ex2	0.9645506264241925	0.7487268158763223
LSTM	Ex2	0.9568131649979904	0.9121498688737892
LSTM	Ex3	0.9521966374231904	1.009655625473227
LSTM	Ex3	0.9459639771176565	1.141295748676587
LSTM	Ex3	0.9478141213098541	1.1022188220568836
LSTM	Ex3	0.9394106581153419	1.2797085096110523
LSTM	Ex3	0.951292575098794	1.0287503410413759
LSTM	Ex3	0.939346354123422	1.2810666753065698
LSTM	Ex3	0.9492891455676549	1.0710648098845164
LSTM	Ex3	0.9464187767318671	1.1316899183709657
LSTM	Ex3	0.9481679156131038	1.0947463266239033
LSTM	Ex3	0.9504384421056448	1.0467904983639853

Fonte: Autor do relatório.

Tabela 23 – Resultados numéricos de todos os experimentos para os testes com os Modelos *Naive* e AR. Ações PETR4.SA.

Technique	Period	R2	MSE
NaiveModel	2019	0.9103626544890717	0.24469233638800086
NaiveModel	2020	0.9665215931008019	0.7070979955300248
AR	2019	0.9326991100961571	0.18371820247125897
AR	2020	0.9784662096310616	0.4623192293652812

Fonte: Autor do relatório.